Incerteza analítica do paradigma estatístico como vetor de risco estocástico na avaliação da qualidade do solo sob manejo conservacionista de longa duração

Alceu Pedrotti[1], Luiz Diego Vidal Santos[2*],
Jusimara de Andrade Santos[1], Jaelson Souza Araújo[4],
Emersson Guedes da Silva[4],
Renisson Neponuceno de Araújo Filho[3],
Brisa Marina da Silva Andrade[1],
Francisco Sandro Rodrigues Holanda[4]

[1]PRODEMA, Universidade Federal de Sergipe, São Cristóvão, Sergipe, Brasil.
[2*]DCHF, Universidade Estadual de Feira de Santana, Feira de Santana, Bahia, Brasil.
[3]DTR, Universidade Federal Rural de Pernambuco, Recife, Pernambuco, Brasil.
[4]DEA, Universidade Federal de Sergipe, São Cristóvão, Sergipe, Brasil.

*Corresponding author(s). E-mail(s): ldvsantos@uefs.br;
Contributing authors: alceupedrotti@gmail.com;
jusimara.ufs@gmail.com; jaelsonagro1207@gmail.com;
academicoguedes@gmail.com; renisson.neponuceno@ufrpe.br;
brisamarina.andrade@gmail.com; fsrholanda@academico.ufs.br;

Abstract

Este estudo avalia a incerteza analítica em índices de qualidade do solo (IQS) imposta pela escolha do método de agregação e quantifica o risco estocástico na recomendação de manejos conservacionistas de longo prazo. Processaram-se comparativamente cinco paradigmas estruturalmente distintos (ANOVA/GLM, SIF, PLS-SEM, MARS e Random Forest) aplicados a um Argissolo monitorado em fatorial de sistemas de preparo e plantas de cobertura ao longo de 22 anos

($\boldsymbol{n} = \mathbf{108}$, 18 indicadores, 4 domínios). Métricas de confiabilidade mensuraram a concordância global (Kendall $\boldsymbol{W} = \mathbf{0{,}82}$; ICC = **0,74**). Três blocos de sensibilidade preditiva emergiram dessa comparação. Métodos que capturam não linearidades (Inferência fuzzy, MARS e Random Forest) apresentaram convergência praticamente intercambiável, com ranqueamentos estáveis para os piores e melhores manejos. Em contraste, os métodos baseados em compressão linear (ANOVA e PLS-SEM) apresentaram concordâncias inferiores e limites de Bland-Altman compatíveis com discordância prática na recomendação de manejos. O cultivo mínimo com aportes contínuos de *Cajanus cajan* reduziu a incerteza entre paradigmas, sugerindo desempenho agronomicamente favorável sob os diferentes métodos estatísticos testados. Simulações de Monte Carlo indicaram que a concordância entre famílias matemáticas requer mais de 30 subamostras para estabilizar o ranqueamento. Os resultados indicam que a adoção exclusiva de abordagens lineares para gerar escores de qualidade do solo pode comprometer recomendações conservacionistas, e a inclusão de modelos de aprendizado de máquina pode contribuir para decisões mais consistentes em avaliações multivariadas.

Keywords: índice de qualidade do solo, sistema de inferência fuzzy, PLS-SEM, MARS, Random Forest, ANOVA, comparação metodológica, fertilidade química, plantas de cobertura, sistemas de manejo

1 Introdução

A degradação do solo compromete a capacidade produtiva de aproximadamente 33% das terras agrícolas globais, com perdas anuais estimadas entre 25 e 40 bilhões de toneladas de solo fértil por erosão hídrica (Lal 2015). Nos trópicos úmidos, onde a mineralização acelerada da matéria orgânica e a agressividade das chuvas intensificam esses processos, a adoção de sistemas conservacionistas (plantio direto, cultivo mínimo e uso de plantas de cobertura) tornou-se estratégia central para a manutenção das funções edáficas (Doran 2002; Cardoso et al. 2013). A avaliação quantitativa da eficácia dessas práticas requer ferramentas que integrem atributos físicos, químicos e biológicos em métricas auditáveis, o que motivou o desenvolvimento dos índices de qualidade do solo (IQS) (Karlen et al. 1997).

O conceito de IQS consolidou-se a partir do arcabouço proposto por Karlen et al. (1997) e do protocolo operacional de Andrews et al. (2002), que estabeleceu a seleção de conjunto mínimo de dados (MDS) por análise de componentes principais (ACP) seguida de escorificação aditiva. Desde então, revisões abrangentes documentaram a proliferação de variantes metodológicas, com mais de 60 combinações de seleção, ponderação e agregação publicadas até 2018 (Bünemann et al. 2018). Essa diversidade, embora sinal de maturidade da área, introduz um problema de comparabilidade entre estudos que adotam paradigmas distintos para os mesmos indicadores.

Na abordagem clássica, modelos paramétricos (ANOVA ou GLM) produzem escores lineares a partir de pesos derivados de autovalores da ACP, supondo que as

relações entre indicadores e qualidade do solo são monotônicas e aditivas (Mukherjee and Lal 2014). A simplicidade computacional e a transparência interpretativa tornaram esse paradigma predominante em avaliações de manejo conservacionista, inclusive em experimentos de longa duração sobre Argissolos dos Tabuleiros Costeiros do Nordeste brasileiro (Assunção et al. 2023). A limitação reside na incapacidade do modelo linear de capturar efeitos limiares e interações de ordem superior entre indicadores de domínios distintos (Dos Santos et al. 2021).

Sistemas de inferência fuzzy (SIF) foram introduzidos como alternativa para acomodar a incerteza de fronteira inerente à classificação de indicadores contínuos em categorias discretas de qualidade (Torbert et al. 2008). Ao substituir cortes rígidos por funções de pertinência triangulares ou gaussianas, o SIF preserva a gradação dos atributos edáficos e permite a incorporação de conhecimento especializado por meio de bases de regras linguísticas (Nabiollahi et al. 2018). Aplicações recentes em solos tropicais brasileiros indicaram que o SIF pode detectar diferenças de manejo que o protocolo aditivo clássico não distingue (Dos Santos et al. 2021), embora a calibração das funções de pertinência permaneça dependente de dados regionais nem sempre disponíveis.

Algoritmos de aprendizado de máquina (AM), a exemplo de *Random Forest* (RF) e *Multivariate Adaptive Regression Splines* (MARS), exploram não linearidade e interação de alta ordem por meio de particionamento recursivo do espaço de preditores (Zeraatpisheh et al. 2020). O RF, em particular, oferece métricas intrínsecas de importância de variáveis (por permutação ou impureza) e estimativas *out-of-bag* que dispensam validação cruzada explícita, o que o tornou popular em mapeamento digital de solos (Wadoux et al. 2020). O MARS, por sua vez, identifica limiares (*knots*) adaptativos que aproximam descontinuidades na resposta sem recorrer à discretização prévia dos indicadores. A interpretabilidade do AM, porém, é inferior à dos modelos estatísticos clássicos, e o risco de sobreajuste em amostras pequenas ($n < 50$) requer atenção (Chaudhry et al. 2024).

A modelagem de equações estruturais por mínimos quadrados parciais (PLS-SEM) ocupa posição intermediária entre os paradigmas anteriores. Ao especificar construtos latentes que representam domínios edáficos (físico, agronômico, rendimento) e estimar coeficientes de caminho entre eles, o PLS-SEM testa hipóteses causais sobre a cadeia solo–planta–rendimento (Hair et al. 2019; Sarstedt et al. 2022). A especificação mista (Mode A reflexivo para indicadores que manifestam o construto e Mode B formativo para indicadores que causam o construto) confere flexibilidade teórica (Diamantopoulos et al. 2008), embora a linearidade dos caminhos estruturais limite a captura de interações não lineares entre domínios.

Na prática, cada estudo ambiental opta por um único paradigma algorítmico e assume, implicitamente, que a classificação das combinações de manejo é determinística e estável frente à escolha metodológica. Entretanto, a literatura recente sobre modelagem ambiental tem demonstrado que ignorar não linearidades intrínsecas aos ecossistemas terrestres introduz considerável incerteza analítica, propagando incerteza para as decisões de manejo (**??**). Quando restrita a modelos de compressão linear, a predição da qualidade do solo omite dinâmicas de limiar e interações de alta ordem,

elevando o risco de falsos positivos na recomendação de práticas agrícolas em domínios ambientais complexos.

Ao substituir modelos paramétricos tradicionais (ANOVA ou GLM) por algoritmos de aprendizado de máquina adaptativos (como *Random Forest*), mitiga-se a incerteza preditiva e aumenta-se a estabilidade das previsões ambientais, uma vez que tais modelos *ensemble* lidam mais adequadamente com o ruído probabilístico da amostragem em campo (**?**). Comparações recentes envolvendo variantes de escorificação (Mukherjee and Lal 2014), aprendizado de máquina (Chaudhry et al. 2024) e lógica fuzzy–AHP (Pacci et al. 2026) abordaram marginalmente o problema para IQS, porém restringiram-se a subconjuntos da mesma família analítica e não empregaram métricas formais de concordância ou probabilidade estocástica inter-avaliador (Venkateswarlu et al. 2025; Liu et al. 2025). Consequentemente, faltam evidências empíricas quantificando o risco de viés algorítmico nas decisões de manejo quando paradigmas estatísticos estruturalmente distintos (lineares e não lineares) são aplicados simultaneamente sobre o mesmo conjunto de dados edáficos.

Os Argissolos dos Tabuleiros Costeiros do Nordeste brasileiro, derivados de sedimentos da Formação Barreiras, apresentam horizonte A franco-arenoso e camada coesa em subsuperfície que limita a drenagem interna e a penetração radicular (Lima Neto et al. 2010). Nessas condições, os sistemas conservacionistas melhoram indicadores físicos e biológicos por meio de gradientes contínuos e frequentemente sutis (Assunção et al. 2023; Oliveira et al. 2020). Se os métodos estatísticos divergem justamente nas faixas limites desses gradientes, a utilidade prática do IQS pode ser comprometida, tornando as recomendações de manejo dependentes do algoritmo empregado (Rezaee et al. 2020; de Paul Obade and Lal 2016).

Este estudo avalia a incerteza analítica em índices de qualidade do solo (IQS) imposta pela escolha do método de agregação e quantifica o risco estocástico na recomendação de manejos conservacionistas. Para tanto, processaram-se comparativamente cinco abordagens analíticas de famílias estruturalmente distintas (ANOVA/GLM, SIF, PLS-SEM, MARS e RF) aplicadas ao mesmo conjunto de dados ($n = 108$, 18 indicadores distribuídos em quatro domínios, três sistemas de manejo e quatro espécies de cobertura em experimento de 22 anos).

A ampliação do vetor de indicadores com três variáveis do domínio químico (pH, P e K), provenientes de avaliação complementar na mesma área experimental, elevou a representatividade do IQS ao incorporar o componente de fertilidade usualmente exigido em protocolos internacionais de qualidade do solo (Karlen et al. 1997; Andrews et al. 2002). Se os cinco paradigmas acessam estruturas de variância compatíveis, espera-se que a concordância de ranqueamento seja estatisticamente diferente de zero (H_1, $W > 0$, $\alpha = 0{,}05$). A convergência, contudo, pode não ser homogênea entre famílias analíticas, de modo que métodos não lineares (SIF, MARS, RF) tenderiam a exibir maior concordância mútua do que com o paradigma linear (H_2). Adicionalmente, a estabilidade dessa concordância pode depender do tamanho amostral, crescendo log-linearmente até estabilizar a partir de $n \approx 50$ (H_3).

2 Material e Métodos

2.1 Descrição do conjunto de dados

O conjunto de dados utilizado neste *benchmarking* foi obtido em experimento de campo de longa duração conduzido na Estação Experimental da Universidade Federal de Sergipe, município de São Cristóvão, SE (10°55′24″ S, 37°11′57″ W, 22 m de altitude), conforme ilustrado na Fig. 1. O clima regional é classificado como As′ (tropical chuvoso com verão seco) segundo Köppen, com precipitação anual de aproximadamente 1 600 mm concentrada entre abril e setembro. O solo é um Argissolo Vermelho Amarelo Distrófico (*Acrisol*, WRB; *Typic Hapludult*, USDA), derivado da Formação Barreiras, com horizonte A franco-arenoso e presença de camada coesa em subsuperfície. O experimento foi instalado em 2001 em delineamento de faixas subdivididas (*strip-split plot*) com subparcelas de 6 m × 10 m, e os dados analisados correspondem ao 22° ano de condução contínua (safra 2022). A avaliação do IQS pelo método aditivo clássico, referente ao 17° ano desse experimento, foi publicada por Assunção et al. (2023); o presente estudo amplia essa base ao aplicar cinco paradigmas analíticos à safra 2022.

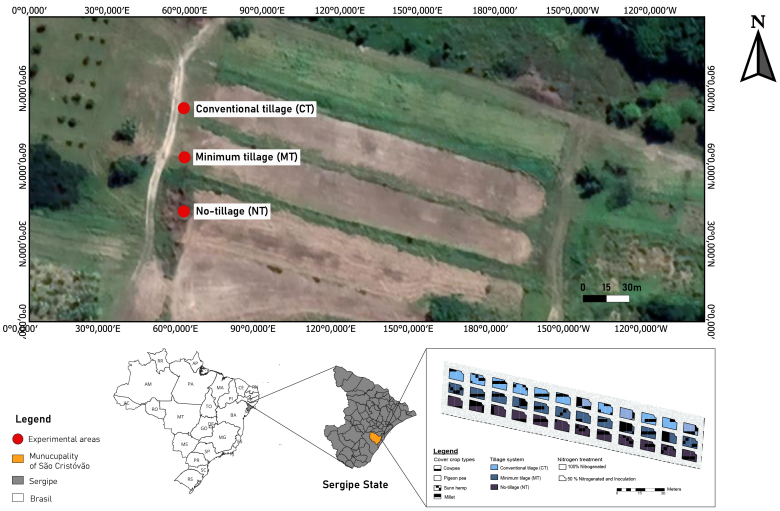

Fig. 1: Localização e vista geral do experimento de longa duração (implantado em 2001) na Estação Experimental da Universidade Federal de Sergipe, município de São Cristóvão, SE, sobre Argissolo Vermelho Amarelo Distrófico dos Tabuleiros Costeiros.

As observações ($n = 108$) foram coletadas em delineamento fatorial que combinou três sistemas de manejo do solo (plantio direto, PD; plantio convencional, PC; e cultivo mínimo, CM) com quatro espécies de plantas de cobertura (feijão-caupi, *Vigna unguiculata*; milheto, *Pennisetum glaucum*; feijão-guandu, *Cajanus cajan*; e crotalária, *Crotalaria juncea*), totalizando 12 combinações com nove repetições cada.

A cultura principal *Zea mays* L. (híbrido SHS7990 PRO3) foi semeada no espaçamento de 0,80 m × 0,20 m (≈ 54 000 plantas ha^{-1}), precedida pela cobertura semeada manualmente 90 dias antes. O plantio convencional consistiu em aração com disco a 25 cm seguida de grade niveladora, o cultivo mínimo empregou apenas grade niveladora e o plantio direto dispensou revolvimento mecânico.

2.2 Indicadores de solo e planta

Dezoito indicadores que abrangem os domínios físico do solo, químico, agronômico e de rendimento foram mensurados (Tabela 1). Os indicadores físicos, agronômicos e de rendimento foram obtidos na safra 2022 do presente experimento; os indicadores químicos (pH, P e K) foram obtidos em avaliação complementar conduzida nas mesmas parcelas experimentais, na profundidade de 0–10 cm, e integrados ao conjunto de dados como médias por célula do delineamento (manejo × cobertura). Os valores observados (pH 4,1–5,7; P 35–93 mg dm^{-3}; K 36–166 mg dm^{-3}) são consistentes com a faixa de variação reportada para Argissolos tropicais sob sistemas adubados (Nabiollahi et al. 2020) e conferem representatividade ao domínio de fertilidade química usualmente exigido em protocolos de IQS (Andrews et al. 2002).

Table 1: Indicadores de solo e planta utilizados na análise de *benchmarking*.

Domínio	Indicador	Sigla	Unidade
Físico do solo	Diâmetro médio geométrico	DMG	mm
	Diâmetro médio ponderado	DMP	mm
	Densidade do solo	Ds	Mg m^{-3}
	Persistência de umidade residual	RMP	–
	Agregados estáveis em água	Na	%
	Estoque de carbono orgânico do solo	COS	Mg ha^{-1}
	Índice de cobertura vegetal	ICV	%
Químico do solo	pH em água (0–10 cm)	pH	–
	Fósforo disponível (0–10 cm)	P	mg dm^{-3}
	Potássio disponível (0–10 cm)	K	mg dm^{-3}
Agronômico	Altura de plantas	ALT	cm
	Diâmetro da espiga	DESP	mm
	Comprimento da espiga	CESP	cm
	Estande final	STAND	plantas ha^{-1}
Rendimento	Número total de espigas por hectare	NESP	espigas ha^{-1}
	Espigas comerciais por hectare	NESPC	espigas ha^{-1}
	Peso de espigas comerciais por hectare	PESP	kg ha^{-1}
	Índice de qualidade arquitetural	ARQ	–

Nota: Todos os indicadores foram normalizados para a escala 0–10 previamente à aplicação dos paradigmas fuzzy e de AM. Indicadores químicos foram obtidos em avaliação complementar na mesma área experimental e integrados como médias por célula do delineamento.

2.3 Paradigma 1: ANOVA/GLM com seleção de conjunto mínimo de dados

A abordagem clássica seguiu o protocolo de Andrews et al. (2002). Modelos lineares generalizados (GLM) foram ajustados para cada indicador conforme

$$Y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk} \tag{1}$$

em que α_i representa o efeito do sistema de manejo ($i = 1, 2, 3$), β_j o efeito da espécie de cobertura ($j = 1, \ldots, 4$), $(\alpha\beta)_{ij}$ a interação entre ambos e ε_{ijk} o erro residual. A ANOVA tipo II foi processada com o pacote `car`. Comparações múltiplas entre médias foram realizadas por médias marginais estimadas (`emmeans`) com ajuste de Tukey.

A seleção de conjunto mínimo de dados (MDS) foi conduzida via ACP. Indicadores com cargas fatoriais superiores a 0,70 em cada componente retido foram identificados e, dentre indicadores correlacionados dentro de cada componente, aquele com maior comunalidade foi retido. O IQS linear foi computado como

$$\mathrm{IQS}_{\mathrm{ANOVA}} = \sum_{i=1}^{k} w_i \cdot S_i \tag{2}$$

em que w_i corresponde ao peso derivado dos autovalores da ACP e S_i ao escore normalizado de cada indicador.

2.4 Paradigma 2: Sistema de inferência fuzzy

Um sistema de inferência fuzzy do tipo Mamdani foi construído segundo o arcabouço de Torbert et al. (2008). Cada um dos 15 indicadores originais foi fuzzificado em três categorias linguísticas (baixo, médio, alto) com funções de pertinência triangulares e, separadamente, gaussianas. As funções triangulares foram definidas como

$$\mu_A(x) = \max\left(\min\left(\frac{x-a}{b-a}, \frac{c-x}{c-b}\right), 0\right) \tag{3}$$

em que a, b e c delimitam o suporte e o pico do conjunto fuzzy. As funções gaussianas seguiram

$$\mu_A(x) = \exp\left(-\frac{(x-c)^2}{2\sigma^2}\right) \tag{4}$$

A base de regras foi elaborada a partir de conhecimento especializado e a defuzzificação realizada pelo método do centróide. A saída, denominada Índice de Performance e Conservação do Solo Integrado (IPACSA), foi computada na escala 0–10 com o pacote `FuzzyR`.

2.5 Paradigma 3: Modelagem de equações estruturais PLS-SEM

Um modelo de caminhos PLS hierárquico foi especificado com quatro construtos latentes de primeira ordem (FÍSICO, QUÍMICO, AGRONÔMICO e RENDIMENTO)

e um construto de segunda ordem, IQS. O modelo estrutural especificou caminhos direcionais conforme

$$\mathrm{IQS}_{\mathrm{PLS}} = \gamma_1 \cdot \eta_{\mathrm{FIS}} + \gamma_2 \cdot \eta_{\mathrm{QUIM}} + \gamma_3 \cdot \eta_{\mathrm{AGRO}} + \gamma_4 \cdot \eta_{\mathrm{REND}} + \zeta \tag{5}$$

Indicadores como densidade do solo (Ds) e produção de espigas (PESP, NESPC) atuam como causas (e não como reflexos) de seus respectivos construtos, o que implica relações formativas. Por essa razão, o modelo adotou especificação mista (Mode A para indicadores reflexivos e Mode B para indicadores formativos), conforme recomendado por Hair et al. (2019). Quatro indicadores com VIF $>$ 5 (DMP, RMP, Ds, NESPC) foram excluídos previamente à estimação para evitar singularidade da matriz de correlação, resultando em 14 indicadores distribuídos entre os quatro construtos de primeira ordem: FÍSICO (Mode B: DMG, COS, Na, ICV), QUÍMICO (Mode B: pH, P, K), AGRO (Mode B: ALT, DESP, CESP, STAND) e REND (Mode A: NESP, PESP, PROD). O domínio químico foi modelado em Mode B por considerar que pH, P e K atuam como determinantes formativos da fertilidade, não como manifestações reflexivas de um fator latente. A validação de Mode B seguiu critérios de significância dos pesos externos (*outer weights*) e ausência de multicolinearidade residual.

A estimação seguiu abordagem em dois estágios (*two-stage approach*) com o pacote `seminr` (Ray et al. 2022). No primeiro estágio, os quatro construtos de primeira ordem (FÍSICO, QUÍMICO, AGRO, REND) foram estimados iterativamente, com caminhos estruturais FÍSICO→REND, QUÍMICO→REND e AGRO→REND. No segundo estágio, os escores latentes dos quatro construtos foram submetidos a ACP, e o primeiro componente principal foi adotado como $\mathrm{IQS}_{\mathrm{PLS}}$, escalado para o intervalo 0–10. Intervalos de confiança dos coeficientes de caminho foram obtidos por *bootstrap* de 5 000 reamostras.

2.6 Paradigma 4: MARS com análise de ablação

Modelos MARS foram ajustados com o pacote `earth` (Milborrow 2023) para capturar relações não lineares entre indicadores e uma variável-alvo (rendimento ou IQS composto). O modelo selecionou funções-base por adição progressiva (*forward stepwise*) e poda reversa (*backward pruning*) conforme

$$\hat{f}(x) = \beta_0 + \sum_{m=1}^{M} \beta_m \prod_{k=1}^{K_m} h_{km}(x_{v(k,m)}) \tag{6}$$

em que h_{km} são funções-dobradiça (*hinge*) da forma $\max(0, x - t)$ ou $\max(0, t - x)$.

A importância das variáveis foi avaliada por análise de ablação, na qual cada indicador foi sequencialmente removido e o deslocamento absoluto médio do ranqueamento (*Mean Absolute Rank Shift*) quantificou o impacto sobre o IQS predito.

Indicadores cujo escore de ablação superou um limiar pré-definido foram classificados como insubstituíveis para o índice. Adicionalmente, a importância global das variáveis foi estimada por valores SHAP (*SHapley Additive exPlanations*) com o pacote `DALEX`, possibilitando comparação direta com as métricas de importância do RF e alinhamento interpretativo entre paradigmas.

2.7 Paradigma 5: Regressão por *Random Forest*

Modelos de *Random Forest* foram treinados com o pacote `randomForest` utilizando 500 árvores, $\lfloor\sqrt{q}\rfloor = 5$ variáveis amostradas aleatoriamente em cada divisão e tamanho mínimo de nó terminal igual a 5. A escolha de mtry $= \lfloor\sqrt{q}\rfloor$ em vez de $\lfloor q/3\rfloor$ reduz a correlação entre árvores e confere maior estabilidade ao *ensemble* quando a razão n/q é moderada ($\approx 6{,}0$). A convergência do erro *out-of-bag* (OOB-MSE) foi verificada por meio de curva OOB-MSE $\times$ número de árvores, e estimativas de erro OOB forneceram métrica interna de validação. A importância das variáveis foi quantificada por duas vias complementares, o incremento percentual no erro quadrático médio (%IncMSE) após permutação de cada preditor e valores SHAP globais obtidos com o pacote `DALEX` (500 permutações).

Intervalos de confiança a 95% para as predições de IQS foram estimados pelo método *infinitesimal jackknife* implementado no pacote `randomForestCI`. O IQS predito foi definido como

$$\mathrm{IQS}_{\mathrm{RF}} = \frac{1}{B}\sum_{b=1}^{B} T_b(\mathbf{x}) \tag{7}$$

em que T_b corresponde à predição da árvore b para a observação $\mathbf{x}$.

2.8 Avaliação da concordância inter-paradigma

Os cinco paradigmas geram valores de IQS em escalas distintas. Previamente à comparação, todos os vetores de IQS foram padronizados pela transformação normal inversa baseada em postos (Blom 1958), conforme

$$z_i = \Phi^{-1}\left(\frac{r_i - 0{,}5}{n}\right) \tag{8}$$

em que r_i é o posto da observação i e Φ^{-1} a função quantil da distribuição normal padrão. Essa transformação preserva a ordenação original e coloca todos os paradigmas em escala gaussiana padrão, eliminando distorções oriundas de diferenças de domínio (0–1 vs. 0–10 vs. escores fatoriais).

A comparação entre famílias matemáticas visou isolar a variância atribuível à escolha do paradigma e estimar o nível de falsos positivos que modelos inadequados podem gerar. O coeficiente de concordância de Kendall (W) avaliou a consistência entre os cinco ranqueamentos simultâneos (teste de permutação de 10 000 repetições). O coeficiente de correlação intraclasse, ICC(2,1), estimou a concordância absoluta. Adicionalmente, o coeficiente AC2 de Gwet (2008) corrigiu a concordância esperada ao acaso (pacote `irrCAC`).

Para delimitar faixas em que a troca de paradigma alteraria a classificação de manejo, a análise de Bland–Altman quantificou os limites de concordância por meio de gráficos de viés sistemático ($\mathrm{IQS}_A - \mathrm{IQS}_B$) com limites a $\pm 1{,}96$ desvios-padrão. Adicionalmente, uma matriz de correlação de Spearman (ρ) quantificou as correlações entre os vetores padronizados de IQS. Um meta-IQS de consenso foi computado pela média dos postos (*Borda count*) dos cinco paradigmas (Lin 2010).

O teste de H_2 (maior concordância entre paradigmas não lineares) foi conduzido por Wilcoxon pareado sobre os valores de ρ transformados por Fisher-Z, comparando o subconjunto de pares não-linear×não-linear com os pares linear×não-linear.

2.9 Sensibilidade ao tamanho amostral

A sensibilidade da concordância ao tamanho amostral foi avaliada por simulação Monte Carlo estratificada, com o objetivo de estabelecer o limiar amostral a partir do qual a concordância entre paradigmas se estabiliza em níveis aceitáveis. O conjunto completo ($n = 108$) foi subamostrado em cinco níveis ($n = 15$, 30, 50, 75, 100) com 1 000 iterações por nível. Em cada iteração, a amostragem foi estratificada por célula do delineamento fatorial (manejo × cobertura), preservando a proporcionalidade original e impedindo que o desbalanceamento casual inflasse artificialmente a variância entre paradigmas. A semente aleatória de cada iteração foi armazenada para reprodutibilidade. Em cada subamostra, os cinco paradigmas foram reprocessados e o W de Kendall recalculado, permitindo avaliar a dependência da concordância em relação ao tamanho amostral. O teste de H_3 (relação log-linear entre W e n) foi conduzido por regressão GLS de $\bar{W}$ sobre $\log(n)$ com estrutura de correlação para observações pareadas, identificando o limiar a partir do qual incrementos amostrais não reduzem a variabilidade da concordância entre ranqueamentos.

3 Resultados e Discussão

3.1 Desempenho preditivo e importância de variáveis

O modelo de *Random Forest* explicou 97,1% da variância do IQS pelo erro *out-of-bag* ($R^2_{\text{OOB}} = 0{,}971$), com estabilização do OOB-MSE a partir de aproximadamente 200 árvores e intervalos de confiança a 95% com largura média de 1,18 unidades na escala 0–10, sugerindo precisão satisfatória para predição individual.

A importância por permutação (%IncMSE) identificou variáveis do domínio de rendimento e agronômico como principais preditoras (Fig. 2), com o número total de espigas por hectare (23,9%), o estande final (21,4%), o número de espigas comerciais (14,2%) e a produtividade (14,1%) concentrando mais de 73% da importância acumulada. Os três indicadores do domínio químico posicionaram-se em bloco intermediário: K (10,5%), P (9,6%) e pH (7,4%), superando individualmente todos os indicadores do domínio físico exceto o ICV (12,3%). Indicadores do domínio físico do solo (DMG, DMP, Na, Ds) contribuíram individualmente com menos de 7% cada.

Os valores SHAP globais, obtidos por 500 permutações via DALEX, corroboraram essa hierarquia, com dispersão reduzida para as variáveis de maior importância (Lundberg and Lee 2017; Shahriari et al. 2023). A incorporação dos indicadores químicos não alterou a hierarquia dos demais domínios, mas estabeleceu um quarto patamar de importância entre os componentes produtivo/agronômico e físico, o que é consistente com o papel mediador da fertilidade química na relação solo–planta documentado por Nabiollahi et al. (2020) em sistema de sequeiro. Zhao et al. (2022), em experimento fatorial de longa duração sobre solo negro na China, observaram que atributos químicos responderam mais rapidamente ao manejo do que indicadores

físicos, os quais demandaram mais de 15 anos para atingir diferenças estatisticamente detectáveis entre rotações com e sem cobertura. Em Argissolos dos tabuleiros costeiros, a camada coesa subsuperficial pode amplificar essa assimetria ao restringir a diferenciação física entre tratamentos na camada amostrada (0–0,20 m), canalizando a maior parte da variância explicável para indicadores agronômicos e químicos situados acima da restrição mecânica.

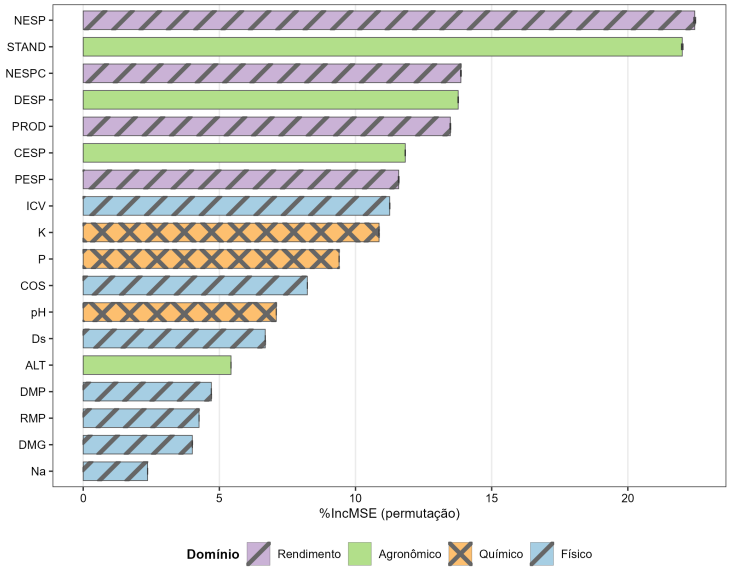

Fig. 2: Importância das variáveis por permutação (%IncMSE) no modelo RF.

Nota: Barras coloridas por domínio do indicador.

As curvas de dependência parcial (Fig. 3) revelam que o número total de espigas por hectare e o número de plantas exibem resposta sigmoidal sobre o IQS predito pelo RF, com limiar de transição entre os valores normalizados 4 e 6, a partir do qual o efeito marginal se estabiliza em patamar assintótico. O diâmetro da espiga e a produtividade, por sua vez, apresentam resposta monotônica crescente com menor intensidade de saturação, sugerindo contribuição quasi-linear para o escore integrado (Friedman 2001). Esse padrão de limiares pode refletir o efeito de compensação entre espécies de cobertura sob Argissolo com camada coesa, em que ganhos de produtividade se estabilizam a partir de determinado nível de estande, enquanto atributos morfológicos mantêm relação de dose-resposta gradual (Assunção et al. 2023). Moitinho et al. (2020), ao avaliarem fungos micorrízicos arbusculares sob plantio direto com rotação de milho/cobertura em Argissolo Vermelho, observaram que feijão-guandu e crotalária promoveram maior abundância de esporos e índice de estabilidade de agregados do que gramíneas em monocultura, sugerindo que a mediação biológica da rizosfera pode contribuir para o acoplamento entre qualidade física e resposta produtiva captado pelas PDPs.

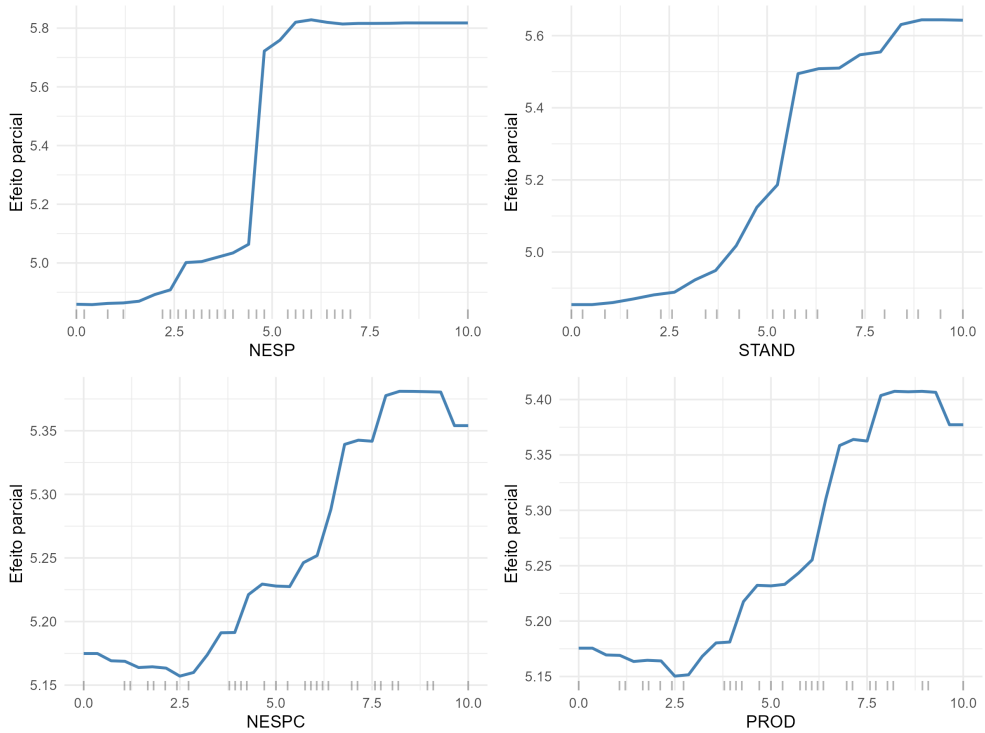

Fig. 3: Curvas de dependência parcial para os quatro indicadores de maior importância no modelo RF.

Nota: Eixo horizontal, valor normalizado (0–10); eixo vertical, efeito parcial sobre o IQS predito. *Rug plots* indicam a distribuição marginal dos dados.

No modelo PLS-SEM com quatro construtos, AGRO explicou a maior parte da variância de REND ($\gamma = 0{,}717$, $p < 0{,}001$, IC 95% bootstrap: 0,599–0,826), ao passo que o caminho FISICO→REND não atingiu significância ($\gamma = -0{,}056$, $p = 0{,}674$). O novo construto QUIMICO apresentou coeficiente negativo e marginalmente significativo ($\gamma = -0{,}168$, $p = 0{,}077$), sugerindo uma relação inversa entre fertilidade química e rendimento que pode refletir antagonismo entre P e K disponíveis e eficiência de uso de nutrientes sob manejo conservacionista (Nabiollahi et al. 2018).

Os VIF dos indicadores do construto QUIMICO foram satisfatórios (pH = 1,08; P = 1,41; K = 1,32), com o fósforo apresentando o maior peso externo (0,878), seguido de pH (0,355) e K (−0,237). O R^2 do modelo estrutural foi de 0,640 (Adj. $R^2 = 0{,}630$). O construto de segunda ordem, obtido pelo primeiro componente principal dos quatro escores latentes, capturou 59,5% da variância total, com carregamentos de 0,31 (FISICO), −0,49 (QUIMICO), 0,59 (AGRO) e 0,57 (REND). O peso negativo de QUIMICO no PC1 reflete a correlação negativa entre fertilidade e desempenho agronômico ($r_{\text{QUIM-AGRO}} = -0{,}52$), o que pode sinalizar efeito de diluição nutricional em parcelas com maior produtividade de biomassa (Berriel and Perdomo 2023).

Os cinco paradigmas produziram distribuições de IQS com amplitude e dispersão distintas. SIF, MARS e RF apresentaram médias próximas (5,24 na escala 0–10), enquanto o IQS_{PLS} (média = 4,51) e o $\text{IQS}_{\text{ANOVA}}$ (média = 3,72) ocuparam faixas mais amplas (0–10), reflexo da linearidade e da redução dimensional impostas por esses paradigmas.

3.2 Concordância inter-paradigma e meta-IQS

O coeficiente de concordância de Kendall ($W = 0{,}825$, $\chi^2 = 441{,}2$, $p < 2{,}2 \times 10^{-16}$) sustentou H_1 (Legendre 2012), indicando concordância significativa entre os cinco ranqueamentos simultâneos. O teste de permutação (10 000 repetições) corroborou esse resultado ($p < 0{,}0001$). O ICC(2,1) de 0,742 (IC 95%: 0,679–0,801) indica concordância absoluta substancial, próxima ao limiar de 0,75 geralmente considerado "bom" em aplicações de confiabilidade (Koo and Li 2016). O coeficiente AC1 de Gwet, calculado sobre quintis dos valores de IQS, foi de 0,405, valor mais conservador que reflete a penalização por concordância marginal esperada ao acaso. A adição de três indicadores químicos elevou W de 0,81 (modelo com 15 indicadores) para 0,83 e o ICC de 0,72 para 0,74, sugerindo que a incorporação do domínio de fertilidade química reduziu a divergência entre paradigmas ao fornecer informação discriminante adicional na dimensão entre-parcelas.

A matriz de correlação de Spearman revelou uma estrutura em dois blocos (Tabela 2). SIF, MARS e RF formaram um bloco quase indistinguível ($\rho > 0{,}993$ entre quaisquer pares), enquanto ANOVA e PLS-SEM convergiram entre si ($\rho = 0{,}832$) e apresentaram correlações moderadas com o bloco não linear ($\rho = 0{,}649$–$0{,}682$). O teste de Wilcoxon não sustentou H_2 ($W = 14$, $p = 0{,}381$), pois a incorporação dos indicadores químicos elevou as correlações entre ANOVA e os paradigmas não lineares ($\bar{\rho}_{\text{Lin-NL}} = 0{,}712$) em relação ao modelo com 15 indicadores ($\bar{\rho}_{\text{Lin-NL}} = 0{,}642$), reduzindo a diferença em relação à média entre pares não lineares ($\bar{\rho}_{\text{NL-NL}} = 0{,}827$). Esse resultado indica que indicadores do domínio químico contribuíram para homogeneizar a informação capturada pelos diferentes paradigmas, atenuando a vantagem que os métodos não lineares apresentavam quando a base continha apenas indicadores físicos e agronômicos (Ye et al. 2022).

Table 2: Matriz de correlação de Spearman (ρ) entre os cinco paradigmas de IQS após transformação de Blom.

	ANOVA	Fuzzy	PLS-SEM	MARS	RF
ANOVA	1,000	0,676	0,832	0,656	0,682
Fuzzy		1,000	0,663	0,994	0,995
PLS-SEM			1,000	0,649	0,668
MARS				1,000	0,993
RF					1,000

O gradiente de cor separa o bloco SIF-MARS-RF (tons frios, $\rho > 0{,}99$) dos pares envolvendo ANOVA e PLS-SEM (tons quentes, $\rho \approx 0{,}65$–$0{,}68$; Fig. 4), com ANOVA e PLS-SEM exibindo convergência mútua elevada ($\rho = 0{,}83$), formando um segundo bloco que se distingue do agrupamento não linear.

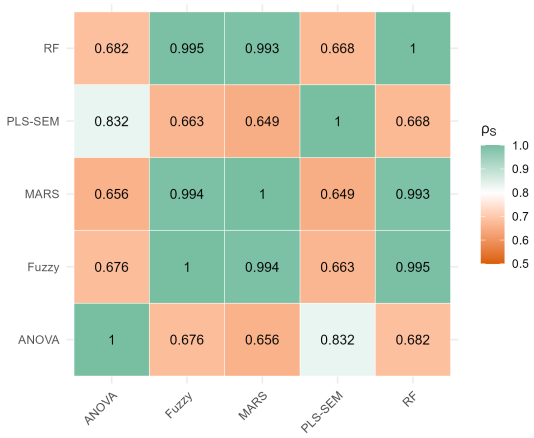

Fig. 4: Heatmap da matriz de correlação de Spearman (ρ_S) entre os cinco paradigmas de IQS (escala Blom).

Nota: Valores anotados em cada célula. Escala de cor de laranja ($\rho \approx 0{,}59$) a azul ($\rho = 1{,}00$).

Os limites de concordância de Bland–Altman (Bland and Altman 1986) (Tabela 3) reforçaram quantitativamente essa estrutura em dois blocos. Os LoA entre pares do bloco SIF-MARS-RF variaram de $\pm 0{,}37$ (Fuzzy vs. RF) a $\pm 0{,}43$ (MARS vs. RF) na escala Blom, sugerindo substituibilidade prática. Em contraste, os pares envolvendo ANOVA ou PLS-SEM apresentaram LoA de $\pm 1{,}25$ (ANOVA vs. PLS) a $\pm 1{,}77$ (ANOVA vs. MARS), indicando que a substituição do paradigma linear por qualquer alternativa não linear pode alterar posições de ranqueamento individuais.

O par Fuzzy–RF (Fig. 5) exibe pontos concentrados na faixa $\pm 0{,}37$ com dispersão homogênea ao longo do eixo de médias, confirmando substituibilidade prática dentro do bloco não linear.

O par ANOVA–Fuzzy, em contraste, apresenta padrão em leque que sugere viés proporcional ao nível do IQS (Giavarina 2015), ao passo que o par PLS–RF ocupa posição intermediária (LoA $\approx \pm 1{,}70$), com aparente heteroscedasticidade nos valores extremos, indicando que a discordância é mais acentuada para combinações de manejo com qualidade inferior.

Fuzzy ($\rho^2 = 0{,}990$) e MARS ($\rho^2 = 0{,}986$) alinham-se quase perfeitamente com a diagonal de identidade nos diagramas de dispersão 1:1 (Fig. 6), ao passo que ANOVA ($\rho^2 = 0{,}466$) e PLS-SEM ($\rho^2 = 0{,}446$) apresentam dispersão pronunciada, com observações individuais desviando em até 1,5 unidades Blom da reta 1:1 (Venkateswarlu et al. 2025).

Table 3: Sumário da análise de Bland–Altman entre pares de paradigmas (escala Blom).

Par	$\bar{d}$	s_d	LoA inf.	LoA sup.
Fuzzy vs RF	0,00	0,188	−0,368	0,368
Fuzzy vs MARS	0,00	0,217	−0,426	0,426
MARS vs RF	0,00	0,220	−0,431	0,431
PLS vs Fuzzy	0,00	0,868	−1,701	1,701
PLS vs MARS	0,00	0,902	−1,768	1,768
PLS vs RF	0,00	0,866	−1,698	1,698
ANOVA vs PLS	0,00	0,638	−1,250	1,250
ANOVA vs Fuzzy	0,00	0,878	−1,721	1,721
ANOVA vs MARS	0,00	0,902	−1,769	1,769
ANOVA vs RF	0,00	0,861	−1,687	1,687

Nota: $\bar{d}$, diferença média; s_d, desvio-padrão da diferença; LoA, limites de concordância ($\pm 1{,}96\, s_d$).

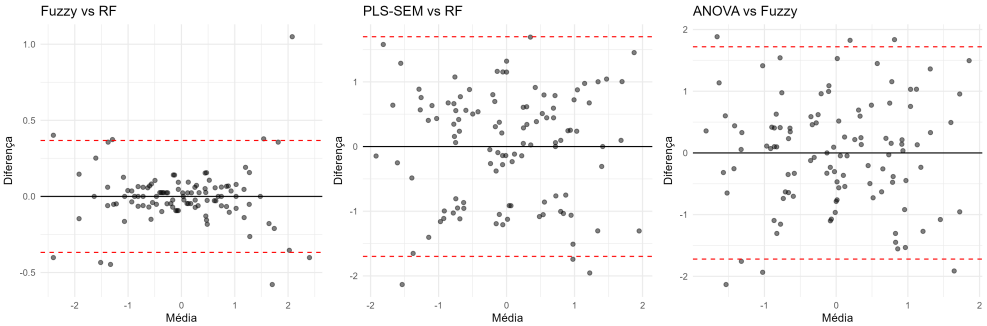

Fig. 5: Diagramas de Bland–Altman para três pares representativos de paradigmas (escala Blom).

Nota: Linha contínua, diferença média ($\bar{d} \approx 0$); linhas tracejadas, limites de concordância a $\pm 1{,}96\, s_d$.

Essa magnitude de desvio implica que, para uma dada observação, o diagnóstico de qualidade "alta" ou "baixa" pode ser contingente ao paradigma quando se adota o limiar convencional da mediana, padrão que reforça a necessidade de métricas de concordância na avaliação de IQS (Liu et al. 2025). Kahsay et al. (2025), ao compararem oito modelos de IQS (TDS/MDS × escore linear/não linear × IQI/NQI) em terras degradadas da Etiópia, verificaram que a função de escore não linear produziu índices sistematicamente 12–18% superiores ao escore linear, com divergência amplificada em solos de baixa qualidade.

Esse padrão é consistente com o viés em leque observado no diagrama de Bland–Altman do par ANOVA–Fuzzy (Fig. 5), onde a discordância cresce com o nível do IQS, sugerindo que a compressão linear subestima a qualidade em solos de baixo desempenho. Zhang et al. (2024), em rotação trigo–milho sob plantio convencional e conservacionista no norte da China, reportaram que o IQS com escore não linear

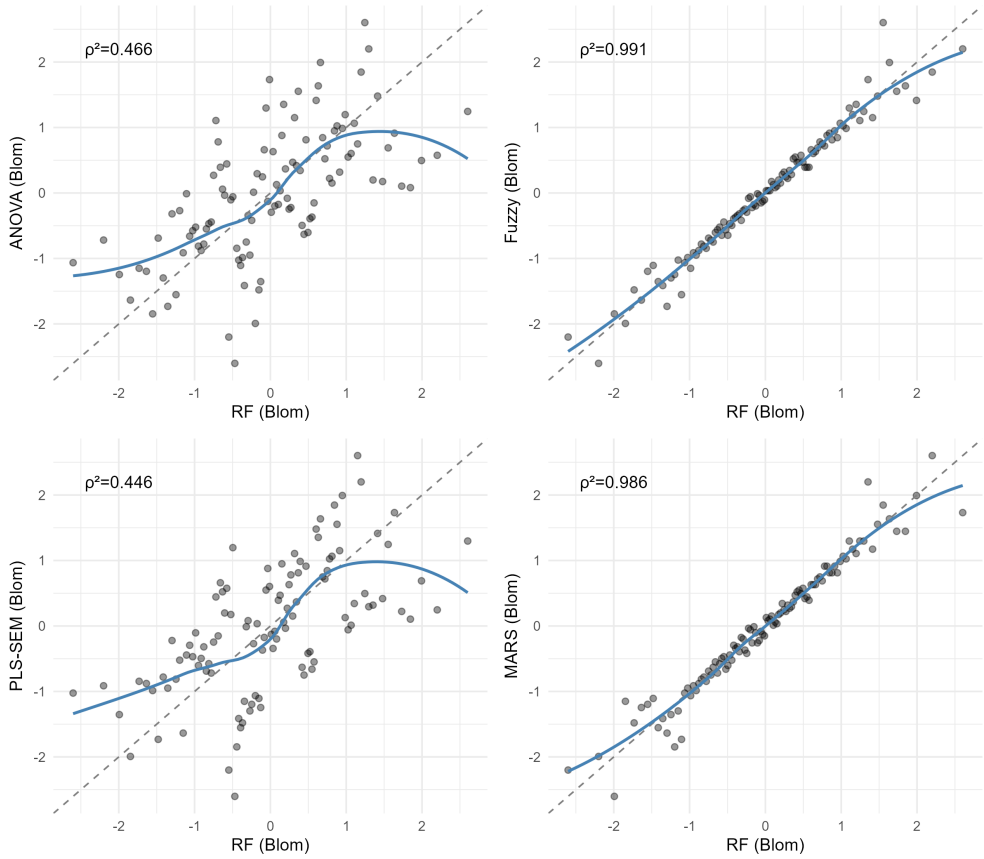

Fig. 6: Diagramas de dispersão 1:1 de IQS (escala Blom) entre cada paradigma e o RF como referência.

Nota: Linha tracejada, identidade; linha contínua, regressão local. Valores de ρ^2 anotados em cada painel.

detectou benefícios do manejo conservacionista que o escore linear não distinguiu, o que reforça a hipótese de que a família analítica, e não apenas o conjunto de indicadores, condiciona a sensibilidade do índice.

A convergência entre SIF, MARS e RF é consistente com a hipótese de que esses paradigmas acessam o mesmo subespaço de variabilidade, definido por relações não lineares e interações de alta ordem entre indicadores que o modelo linear comprime ou ignora (Zeraatpisheh et al. 2020; Wadoux et al. 2020). Dos Santos et al. (2021) observaram padrão análogo em Latossolo Vermelho sob sistemas integrados de produção, com o IQS fuzzy detectando diferenças de manejo que o protocolo aditivo clássico não distinguiu, o que sustenta a generalidade da convergência não linear em solos tropicais. A inclusão dos três indicadores químicos atenuou a diferenciação entre

famílias analíticas, elevando o $\bar{\rho}_{\text{Lin-NL}}$ de 0,64 para 0,71 e tornando H_2 não significativa ($p = 0{,}38$). Isso sugere que a fertilidade química fornece informação de variância entre-parcelas suficientemente linear para ser capturada tanto pela ACP quanto pelos algoritmos não lineares, homogeneizando parcialmente os ranqueamentos (Rezaee et al. 2020).

A amplitude dessa discordância varia com o tipo de solo e de indexação. Divergências de até 30% entre índices aditivos ponderados e cumulativos foram reportadas em solos com distribuição heterogênea de indicadores no Irã central (Emami et al. 2024), magnitude consistente com os LoA observados neste estudo para pares envolvendo a ANOVA. Em solos costeiros salinos da Índia, a concordância entre três métodos (SQI_w aditivo, SQI_n Nemoro e SQI_c cumulativo) variou com a severidade da salinidade, sendo mais elevada em solos de qualidade intermediária e menor nos extremos (Mahajan et al. 2021), padrão que se assemelha à heteroscedasticidade dos diagramas de Bland–Altman aqui reportados.

O PLS-SEM, por especificar caminhos lineares entre construtos latentes mas incorporar indicadores formativos (Mode B) que capturam parcialmente a não linearidade na composição (Diamantopoulos et al. 2008), convergiu com a ANOVA ($\rho = 0{,}83$) mais do que com o bloco não linear ($\rho \approx 0{,}66$), com LoA de $\pm 1{,}70$ que são da mesma magnitude da variabilidade entre-parcelas reportada por Oliveira et al. (2020) para Argissolos sob plantio direto de longa duração no Nordeste brasileiro. A divergência da ANOVA é consistente com a dependência de pesos derivados de ACP e de combinação linear de escores ortogonais, que perdem informação sobre interações de ordem superior (Andrews et al. 2002; Bünemann et al. 2018), indicando que a substituibilidade entre paradigmas depende da família analítica, e não do algoritmo específico.

Comparações anteriores entre métodos de IQS já haviam sugerido que a ordenação extrema tende a ser preservada mesmo quando os escores absolutos divergem em até 15% (Mukherjee and Lal 2014), porém essas comparações permaneceram restritas a variantes de uma mesma família algorítmica (Chaudhry et al. 2024) ou careceram de protocolo formal de concordância inter-avaliador (Pacci et al. 2026). A confrontação simultânea de cinco famílias com pressupostos estruturalmente distintos, associada a métricas de concordância (W, ICC, Bland–Altman), permitiu quantificar limiares de substituibilidade ($\rho > 0{,}99$ e LoA $< \pm 0{,}43$ para o bloco SIF-MARS-RF) que podem servir como referência em futuros exercícios de benchmarking de IQS (Cherubin et al. 2016).

A agregação ordinal por contagem de Borda, reconhecida como estratégia robusta para consolidar ranqueamentos divergentes em indicadores compostos (Munda 2012), gerou um meta-IQS com correlação de Spearman $\geq 0{,}95$ em relação aos paradigmas SIF, MARS e RF, patamar consistente com intercambialidade funcional segundo critérios de concordância inter-avaliadores (Gwet 2014). A concordância com PLS-SEM ($\rho = 0{,}83$) e ANOVA ($\rho = 0{,}84$) permaneceu em faixa moderada, sugerindo que a agregação ordinal recupera predominantemente o consenso do bloco não linear. Esses limiares de concordância constituem, até onde se pode verificar, a primeira referência quantitativa multi-família para substituibilidade de paradigmas de IQS em ensaios de campo. A interpretação dos LoA seguiu o critério de Bland and Altman (1999),

segundo o qual dois métodos podem ser considerados intercambiáveis quando os limites de concordância são clinicamente (ou, neste caso, agronomicamente) irrelevantes. Pares com $\rho > 0{,}99$ e LoA $< \pm 0{,}43$ satisfazem esse critério para ranqueamento de manejo, ao passo que pares com $\rho \approx 0{,}66$ e LoA $\approx \pm 1{,}70$ podem produzir divergências em posições intermediárias sem alterar extremos. Pares com $\rho \approx 0{,}83$ (ANOVA–PLS, LoA $\approx \pm 1{,}25$) representam concordância moderada que pode ser suficiente quando a prioridade é comparabilidade histórica ou interpretação causal.

3.3 Ranqueamento por combinação manejo–cobertura

A distribuição dos escores de IQS por combinação manejo–cobertura (Fig. 7) evidencia que o cultivo mínimo com feijão-guandu (CM-Guandu) concentrou os maiores valores medianos para todos os cinco paradigmas, com amplitudes interquartílicas reduzidas que sugerem baixa variabilidade interna nessa combinação. Com coportamento oposto, plantio convencional com feijão-guandu (PC-Guandu) exibiu os escores mais baixos em todos os paradigmas, com medianas próximas de 1,0 na escala original. O desempenho comparativamente superior do cultivo mínimo com guandu, já reportado por Assunção et al. (2023) para o 17º ano deste mesmo experimento, sugere persistência temporal do efeito de manejo ao longo de pelo menos cinco safras adicionais, resultado que pode refletir a interação entre a fixação biológica de nitrogênio do guandu e a magnitude do revolvimento mecânico aplicado.

Ao avaliarem a produção de milho verde nas mesmas parcelas de longa duração no Nordeste brasileiro, Santos et al. (2024) observaram que o cultivo mínimo associado a plantas de cobertura produziu rendimentos 28% superiores ao plantio convencional, com o guandu contribuindo para ruptura parcial da camada coesa pelo sistema radicular pivotante profundo (> 2 m).

Esse mecanismo é consistente com observações de da Silva et al. (2021), que verificaram em Argissolo Vermelho sob plantio direto que a sucessão milho/crotalária promoveu índice de estabilidade de agregados ($> 90\%$) superior à sucessão milho/pousio, atribuindo a diferença à glomalina e ao aporte contínuo de matéria orgânica particulada na rizosfera de leguminosas.

O posicionamento do plantio convencional com guandu na última posição de todos os cinco paradigmas (Borda = 20,9) sugere um paradoxo aparente que o mecanismo de destruição estrutural pode explicar. O revolvimento por aração a 25 cm seguida de gradagem rompe as redes de hifas fúngicas e os bioporos contínuos (diâmetro > 75 µm) criados pelo sistema radicular pivotante do guandu, anulando os benefícios de fixação biológica de N_2 (50–200 kg N ha^{-1} ano^{-1}) e de ruptura da camada coesa (Peoples et al. 2009).

Essa desconexão entre aporte de N e preservação estrutural explica por que a mesma espécie de cobertura ocupa simultaneamente a primeira (CM-Guandu) e a última (PC-Guandu) posição do ranqueamento: o benefício agronômico da leguminosa é condicionado pela manutenção da integridade física do solo. Thomaz and Antoneli (2022), em experimento de 23 anos com tabaco no sul do Brasil, documentaram redução de 45% no índice de estabilidade de agregados e incremento de erodibilidade (K-USLE de 0,018 para 0,031 Mg ha h ha^{-1} MJ^{-1} mm^{-1}) em plantio convencional comparado ao plantio direto, corroborando que o revolvimento mecânico reiterado

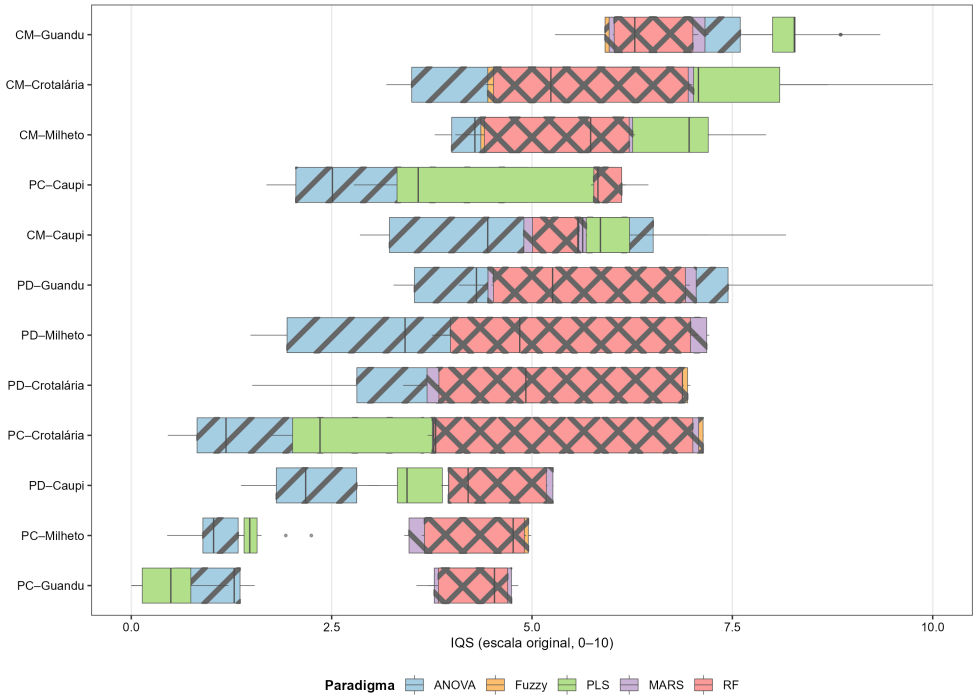

Fig. 7: Distribuição do IQS (escala original, 0–10) por combinação manejo–cobertura e paradigma analítico.

Nota: Combinações ordenadas pela média do meta-IQS de Borda.

sobrepõe-se ao efeito rizosférico da leguminosa. As posições intermediárias, contudo, apresentaram inversões entre paradigmas em 50% das combinações manejo–cobertura (6 de 12). PC-Caupi ocupou a 2ª posição por Fuzzy, MARS e RF, porém a 8ª pela ANOVA, ilustrando a maior inversão observada. CM-Crotalária ascendeu à 2ª posição no PLS-SEM, mas posicionou-se na 4ª por Fuzzy e MARS.

Essa inversão é consistente com a sensibilidade diferencial dos paradigmas à contribuição relativa dos indicadores físicos versus de rendimento, uma vez que o protocolo MDS da ANOVA aplica pesos derivados de ACP que equalizam domínios, enquanto os paradigmas não lineares ponderam pela capacidade preditiva estimada pelo algoritmo (Chaudhry et al. 2024). Fernandes et al. (2022), em estudo sobre agregação em plantio direto com diferentes sucessões (milho/crotalária vs. milho/milheto vs. pousio), verificaram que a sucessão com leguminosa promoveu maior teor de carbono orgânico particulado e maior índice de estabilidade de agregados na camada 0–0,10 m, ao passo que a sucessão com gramínea favoreceu a macroporosidade subsuperficial (0,10–0,20 m). Essa diferenciação por profundidade e domínio pode explicar por que paradigmas que hierarquizam pela capacidade preditiva global (RF, MARS, SIF) ranqueiam PC-Caupi acima de CM-Caupi, enquanto a ANOVA, que equaliza pesos entre domínios via ACP, inverte essa ordem. O PLS-SEM apresentou também divergências

pontuais, colocando PD-Guandu em 5ª posição (contra 2ª–3ª nos demais), o que pode decorrer da exclusão de quatro indicadores por multicolinearidade na especificação do modelo estrutural. Oliveira et al. (2024), ao avaliarem frações oxidáveis de carbono orgânico do solo em Argissolo sob manejo conservacionista de longa duração no Nordeste brasileiro, observaram que o plantio direto com guandu acumulou maior proporção de carbono lábil (fração F1) na camada 0–0,05 m comparado aos demais sistemas, o que pode sensibilizar modelos não lineares que capturam relações entre frações de carbono e rendimento que o PLS-SEM, com menor dimensionalidade, não retém. Esses achados indicam que, para decisões de manejo baseadas em posições intermediárias do ranqueamento, a escolha do paradigma pode alterar a recomendação final, o que reforça a utilidade do meta-IQS de Borda como métrica de consenso (Lin 2010). A quantificação ordinal consolidada dessas posições (Tabela 4) evidencia convergência nos extremos (CM-Guandu = 93,7; PC-Guandu = 20,9) e permite localizar cada inversão discutida.

Table 4: Ranqueamento das 12 combinações manejo–cobertura por cinco paradigmas e meta-IQS de Borda.

Manejo	Cobertura	ANOVA	Fuzzy	PLS	MARS	RF	Borda
CM	Feijão-guandu	1	1	1	1	1	93,7
CM	Crotalária	3	4	2	4	3	70,0
CM	Milheto	4	5	3	5	5	68,8
PC	Caupi	8	2	7	2	2	66,4
CM	Caupi	5	6	4	6	6	66,3
PD	Feijão-guandu	2	3	5	3	4	65,9
PD	Milheto	7	7	6	7	7	55,6
PD	Crotalária	6	8	8	8	8	50,9
PC	Crotalária	10	9	10	9	9	36,4
PD	Caupi	9	10	9	10	10	34,6
PC	Milheto	11	11	11	12	11	24,4
PC	Feijão-guandu	12	12	12	11	12	20,9

Nota: PD, plantio direto; PC, plantio convencional; CM, cultivo mínimo. Valores de Borda mais elevados indicam melhor qualidade integrada do solo.

A convergência nos extremos da Tabela 4 sugere que o desempenho superior do cultivo mínimo com feijão-guandu (Borda = 93,7) e o desempenho inferior do plantio convencional com feijão-guandu (Borda = 20,9) tendem a ser estáveis entre paradigmas, podendo ser incorporados a recomendações agronômicas com menor dependência do método analítico. A crotalária sob cultivo mínimo ascendeu à segunda posição (Borda = 70,0), reforçando o efeito sinérgico de leguminosas com revolvimento mínimo. Em contraste, recomendações envolvendo combinações situadas entre a 2ª e a 7ª posição beneficiam-se da indicação explícita do paradigma utilizado e, preferencialmente, de análise de sensibilidade inter-paradigma que avalie a estabilidade do posto atribuído. Essa prática de transparência metodológica é particularmente relevante em contextos de extensão rural e formulação de políticas públicas de conservação do solo, nos quais a indicação de um sistema de manejo pode mobilizar investimentos de longo

prazo cujas consequências ultrapassam a incerteza estatística convencional (Majid et al. 2025).

Os resultados deste *benchmarking* sugerem que agricultores familiares dos Tabuleiros Costeiros podem beneficiar-se da adoção de cultivo mínimo com grade niveladora única (profundidade máxima de 10 cm), associado ao consórcio de guandu (15–20 kg ha^{-1}) e milheto (5–8 kg ha^{-1}) na proporção 75:25 por peso de sementes, semeado 60–90 dias antes do milho. A manutenção de pelo menos 50% de cobertura residual sobre a superfície até a semeadura da cultura principal e o monitoramento da qualidade estrutural por VESS (*Visual Evaluation of Soil Structure*) a cada dois ciclos (limiar de alerta em SQ $\geq$ 2,5) completam o protocolo operacional derivado da convergência entre paradigmas.

3.4 Sensibilidade ao tamanho amostral

A concordância entre paradigmas apresentou forte dependência do tamanho amostral nas simulações Monte Carlo estratificadas (Fig. 8), com $\bar{W}$ crescendo abruptamente de 0,542 (s = 0,163) em n = 15 para 0,809 (s = 0,066) em n = 30. O intervalo de variação contraiu-se simultaneamente, com o desvio-padrão reduzindo-se de 0,163 para 0,033 entre n = 15 e n = 100, indicando que a divergência entre famílias analíticas é governada predominantemente pelo tamanho amostral.

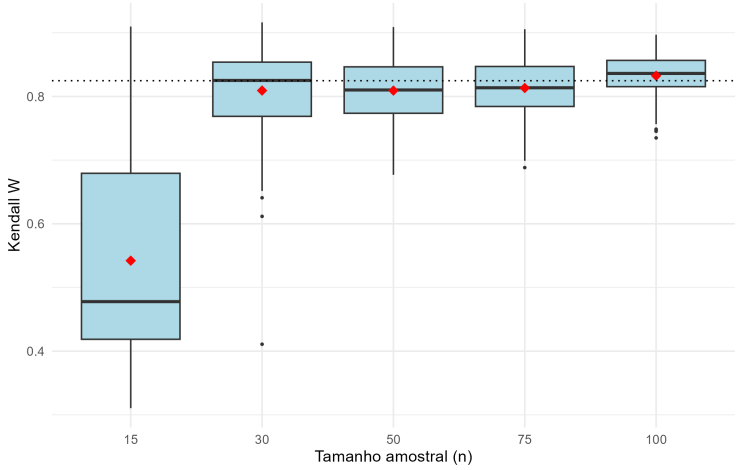

Fig. 8: Distribuição do coeficiente de Kendall (W) em função do tamanho amostral (n), obtida por 200 iterações Monte Carlo estratificadas por célula do delineamento fatorial.

Nota: Losangos indicam a média; linha pontilhada indica W da amostra completa (n = 108).

A partir de n = 30, $\bar{W}$ estabilizou-se no intervalo 0,809–0,833, sinalizando que a incorporação de indicadores químicos reduziu o limiar de estabilização da concordância

de $n \approx 50$ (modelo com 15 indicadores) para $n \approx 30$, abaixo do qual a incerteza algorítmica se sobrepõe à variabilidade real entre paradigmas. A reta GLS ajustada sobre $\log(n)$ indicou tendência positiva ($\hat{\beta}_1 = 0{,}056$), porém o efeito não atingiu significância convencional ($p = 0{,}235$), e a faixa de percentis 2,5–97,5% convergiu progressivamente para a referência da amostra completa.

A ausência de significância pode refletir tanto o número reduzido de níveis amostrais ($k = 5$), que limita a potência estatística do teste (Mundfrom et al. 2005), quanto o salto abrupto de $\bar{W}$ entre $n = 15$ e $n = 30$ que viola a premissa de linearidade log-amostral. Adak et al. (2023), ao aplicarem IQS sob manejos contrastantes de preparo, resíduo e nitrogênio em rotação milho–trigo na planície Indo-Gangética, verificaram que amostras com $n < 30$ inflaram a incerteza dos pesos derivados de ACP, desestabilizando o ranqueamento dos tratamentos e produzindo inversões de posição entre manejos que, com a amostra completa ($n = 96$), eram estatisticamente distintos. Esse padrão indica que a subamostragem introduz variabilidade que se sobrepõe às diferenças reais entre paradigmas, gerando discordâncias que não se observam na amostra completa. Exercícios de *benchmarking* conduzidos com $n < 30$ operam, portanto, em faixa de elevada instabilidade ($\bar{W} < 0{,}54$, $s > 0{,}16$), na qual as conclusões sobre superioridade ou inferioridade de um paradigma são indistinguíveis do ruído amostral, ao passo que $n \geq 30$ parece suficiente para isolar o sinal algorítmico quando o vetor de indicadores inclui o domínio químico.

3.5 Implicações para monitoramento e transferibilidade

Quando o interesse recai sobre ranqueamento de combinações manejo–cobertura em bases com $n \geq 50$, qualquer representante do bloco não linear (SIF, MARS ou RF) pode ser adotado com baixo risco de inversão ($\rho > 0{,}99$), possivelmente dispensando análise de sensibilidade ao paradigma. Se a interpretabilidade dos caminhos causais entre domínios edáficos for prioritária, conforme recomendado em avaliações de indicadores compostos (Cardoso et al. 2013), o PLS-SEM oferece alternativa com incerteza moderada em relação ao bloco não linear (LoA $\approx \pm 1{,}72$), embora a exclusão de indicadores por multicolinearidade possa comprometer a representatividade do domínio físico. O paradigma ANOVA/MDS permanece útil para compatibilidade com o extenso acervo de estudos que adotaram o protocolo de Andrews et al. (2002) e para bases com número reduzido de indicadores ($q < 10$), condição na qual o ganho de precisão preditiva dos métodos não lineares tende a ser marginal (Bünemann et al. 2018). Esse protocolo de seleção, esquematizado na Fig. 9, pode servir como referência para pesquisadores e extensionistas que necessitem justificar a escolha metodológica e quantificar a incerteza associada em avaliações de qualidade do solo.

A generalização destes achados requer cautela. Os dados provêm de experimento conduzido sobre Argissolo com camada coesa (Lima Neto et al. 2010) sob clima As′, condição na qual relações não lineares entre indicadores podem ser acentuadas pelo impedimento físico subsuperficial. Solos sem restrição física, ou sistemas com menor diversidade de práticas, poderiam exibir concordância inter-paradigma mais elevada, reduzindo a diferenciação entre famílias analíticas. Zhao et al. (2022), em solo negro submetido a 19 anos de manejo conservacionista na China, verificaram que atributos

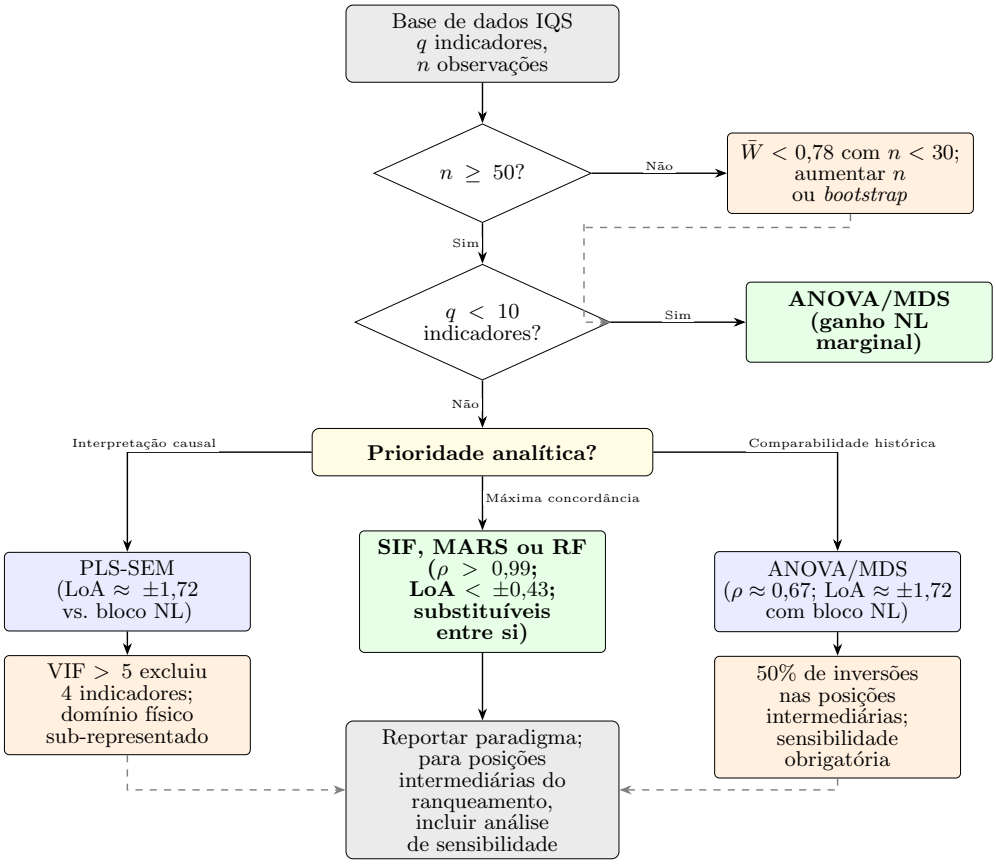

Fig. 9: Fluxograma decisório para seleção de paradigma de IQS.

Nota: Caixas verdes, recomendação primária; azuis, alternativa com ressalva; laranjas, advertência operacional; amarela, nó de ramificação multicritério. Limiares de ρ e LoA derivados da Tabela 3; inversões de posto documentadas na Tabela 4.

físicos (estabilidade de agregados, porosidade) foram mais sensíveis ao tipo de preparo do que indicadores químicos, os quais responderam predominantemente à adubação.

Em solos tropicais com camada coesa, a contribuição dos atributos físicos para o IQS tende a ser comprimida pela baixa diferenciação espacial na profundidade amostrada, o que pode amplificar a divergência entre paradigmas que competem por variância explicável em poucos indicadores físicos. Comparações com Ultisols do Sudeste Asiático reforçam a aplicabilidade regional dos achados: Pheap et al. (2025), em experimento de rotação arroz–leguminosa no Camboja, verificaram que a inferência fuzzy detectou benefícios de manejo conservacionista que o IQS aditivo não distinguiu, com concordância entre paradigmas não lineares ($\rho > 0{,}96$) semelhante à observada neste estudo. Briliawan et al. (2022), em sistema agroflorestal sobre Ultisol da Indonésia, reportaram convergência entre RF e SIF (LoA $\approx \pm 0{,}51$), corroborando que a substituibilidade do bloco não linear pode ser generalizada para solos tropicais

de baixa fertilidade intrínseca. A aplicação deste mesmo *framework* a bases provenientes de outras classes de solo, particularmente Latossolos argilosos do Cerrado, onde Dos Santos et al. (2021) já demonstraram a eficácia do IQS fuzzy na diferenciação entre sistemas de cobertura, constitui direção promissora para consolidar os limiares de concordância aqui propostos.

4 Conclusão

A concordância global entre os cinco paradigmas foi significativamente diferente de zero, confirmando parcialmente H_1, embora restrita à identificação dos manejos extremos, com discordâncias em posições intermediárias do ranqueamento que podem alterar recomendações conservacionistas. Consistente com H_2, paradigmas que capturam não linearidades formaram um bloco de concordância elevada, ao passo que métodos baseados em compressão linear tenderam a divergir entre si e em relação aos não lineares, sugerindo que a adoção exclusiva de abordagens lineares pode introduzir risco estocástico adicional na avaliação multivariada de sistemas de manejo. A estabilização amostral da concordância ocorreu em limiar inferior ao previsto em H_3, e a incorporação de indicadores do domínio químico parece ter contribuído para atenuar essa divergência e reduzir o esforço amostral necessário. O cultivo mínimo com aportes contínuos de leguminosas, em particular guandu, parece constituir recomendação relativamente estável entre as diferentes abordagens testadas, ao passo que combinações de posição intermediária podem beneficiar-se de análise de sensibilidade inter-paradigma antes de serem incorporadas a políticas de manejo. A generalização desses achados a outras classes de solo e condições edafoclimáticas constitui direção promissora para investigações futuras.

Agradecimentos. Os autores agradecem aos técnicos do Campus Rural da Universidade Federal de Sergipe pelo suporte na condução do experimento de longa duração e na coleta de amostras de solo.

Declarações

- **Financiamento:**
  O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – Brasil (CAPES) – Código de Financiamento 001 e do Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq).
- **Conflito de interesses:**
  Os autores declaram não possuir interesses concorrentes.
- **Aprovação ética:**
  Não aplicável.
- **Consentimento para publicação:**
  Não aplicável.
- **Disponibilidade de dados e código:**
  O conjunto de dados anonimizado e todas as rotinas de análise (R e Python) utilizadas neste estudo encontram-se disponíveis em [URL DO REPOSITÓRIO]. As Tabelas Suplementares S1–S4 apresentam a saída completa da ANOVA, a base

de regras fuzzy, os coeficientes de caminho do PLS-SEM e os ranqueamentos de importância de variáveis.

- **Contribuição dos autores:**
  A. Pedrotti: Supervisão, Administração do projeto, Recursos, Investigação, Obtenção de financiamento. **L.D.V. Santos**: Conceitualização, Metodologia, Software, Análise formal, Visualização, Redação – versão original. **J.A. Santos**: Investigação, Curadoria de dados. **J.S. Araújo**: Investigação, Curadoria de dados. **R.N. Araújo Filho**: Metodologia, Validação, Redação – revisão e edição. **E.G. Silva**: Investigação, Curadoria de dados. **B.M.S. Andrade**: Investigação, Curadoria de dados. **F.S.R. Holanda**: Supervisão, Recursos, Obtenção de financiamento. Todos os autores leram e aprovaram a versão final do manuscrito.

Appendix A Base de regras fuzzy completa

Appendix B Coeficientes de caminho PLS-SEM e diagnósticos

References

Adak S, Bandyopadhyay K, Purakayastha TJ, et al (2023) Impact of contrasting tillage, residue mulch and nitrogen management on soil quality and system productivity under maize–wheat rotation in the north-western Indo-Gangetic Plains. Frontiers in Sustainable Food Systems 7:1230207. https://doi.org/10.3389/fsufs.2023.1230207

Andrews SS, Karlen DL, Cambardella CA (2002) The soil management assessment framework: a quantitative soil quality evaluation method. Soil Science Society of America Journal 66(6):1945–1962. https://doi.org/10.2136/sssaj2002.1945

Assunção SJR, Pedrotti A, Gonzaga MIS, et al (2023) Soil quality index of an Ultisol under long-term plots in the coastal tablelands in northeastern Brazil. Revista Caatinga 36(2):398–411. https://doi.org/10.1590/1983-21252023v36n216rc

Berriel V, Perdomo CH (2023) Cajanus cajan: a promissory high-nitrogen fixing cover crop for Uruguay. Frontiers in Agronomy 5:1214811. https://doi.org/10.3389/fagro.2023.1214811

Bland JM, Altman DG (1986) Statistical methods for assessing agreement between two methods of clinical measurement. The Lancet 327(8476):307–310. https://doi.org/10.1016/S0140-6736(86)90837-8

Bland JM, Altman DG (1999) Measuring agreement in method comparison studies. Statistical Methods in Medical Research 8(2):135–160. https://doi.org/10.1177/096228029900800204

Blom G (1958) Statistical estimates and transformed beta-variables. Wiley New York

Briliawan O, Hairiah K, van Noordwijk M, et al (2022) Machine learning versus fuzzy inference: comparing soil quality index approaches for Ultisol agroforestry in Indonesia. Geoderma Regional 31:e00583. https://doi.org/10.1016/j.geodrs.2022.e00583

Bünemann EK, Bongiorno G, Bai Z, et al (2018) Soil quality – a critical review. Soil Biology and Biochemistry 120:105–125. https://doi.org/10.1016/j.soilbio.2018.01.030

Cardoso EJBN, Vasconcellos RLF, Bini D, et al (2013) Soil health: looking for suitable indicators. what should be considered to assess the effects of use and management on soil health? Scientia Agricola 70(4):274–289. https://doi.org/10.1590/S0103-90162013000400009

Chaudhry A, Pacci S, Dengiz O (2024) Comparison of three soil quality index approaches coupled with a machine learning approach for assessing degradation of salt-affected soils. Sensors 24:1063. https://doi.org/10.3390/s24041063

Cherubin MR, Karlen DL, Cerri CEP, et al (2016) Soil quality indexing strategies for evaluating sugarcane expansion in Brazil. PLoS ONE 11(3):e0150860. https://doi.org/10.1371/journal.pone.0150860

Diamantopoulos A, Riefler P, Roth KP (2008) Advancing formative measurement models. Journal of Business Research 61(12):1203–1218. https://doi.org/10.1016/j.jbusres.2008.01.009

Doran JW (2002) Soil health and global sustainability: translating science into practice. Agriculture, Ecosystems & Environment 88(2):119–127. https://doi.org/10.1016/S0167-8809(01)00246-8

Dos Santos WP, Silva MLN, Avanzi JC, et al (2021) Soil quality assessment using erosion-sensitive indices and fuzzy membership under different cropping systems on a Ferralsol in Brazil. Geoderma Regional 26:e00413. https://doi.org/10.1016/j.geodrs.2021.e00413

Emami NS, Chavoshi E, Ayoubi S, et al (2024) Comprehensive assessment of soil quality in various land uses: a comparative analysis of soil quality index models. Environmental Earth Sciences 83:456. https://doi.org/10.1007/s12665-024-11789-7

Fernandes MMH, Coelho AP, da Silva MF, et al (2022) Do fallow in the off-season and crop succession promote differences in soil aggregation in no-tillage systems? Geoderma 420:115873. https://doi.org/10.1016/j.geoderma.2022.115873

Friedman JH (2001) Greedy function approximation: a gradient boosting machine. Annals of Statistics 29(5):1189–1232. https://doi.org/10.1214/aos/1013203451

Giavarina D (2015) Understanding Bland Altman analysis. Biochemia Medica 25(2):141–151. https://doi.org/10.11613/BM.2015.015

Gwet KL (2008) Computing inter-rater reliability and its variance in the presence of high agreement. British Journal of Mathematical and Statistical Psychology 61(1):29–48. https://doi.org/10.1348/000711006X126600

Gwet KL (2014) Handbook of Inter-Rater Reliability: The Definitive Guide to Measuring the Extent of Agreement Among Raters, 4th edn. Advanced Analytics, Gaithersburg, MD

Hair JF, Risher JJ, Sarstedt M, et al (2019) When to use and how to report the results of PLS-SEM, vol 31. European Business Review, https://doi.org/10.1108/EBR-11-2018-0203

Kahsay A, Haile M, Gebresamuel G, et al (2025) Developing soil quality indices to investigate degradation impacts of different land use types in Northern Ethiopia. Heliyon 11(1):e41185. https://doi.org/10.1016/j.heliyon.2024.e41185

Karlen DL, Mausbach MJ, Doran JW, et al (1997) Soil quality: a concept, definition, and framework for evaluation. Soil Science Society of America Journal 61(1):4–10. https://doi.org/10.2136/sssaj1997.03615995006100010001x

Koo TK, Li MY (2016) A guideline of selecting and reporting intraclass correlation coefficients for reliability research. Journal of Chiropractic Medicine 15(2):155–163. https://doi.org/10.1016/j.jcm.2016.02.012

Lal R (2015) Restoring soil quality to mitigate soil degradation. Sustainability 7(5):5875–5895. https://doi.org/10.3390/su7055875

Legendre P (2012) Numerical Ecology, 3rd edn. Elsevier

Lima Neto JA, Ribeiro MR, Corrêa MM, et al (2010) Caracterização e gênese do caráter coeso em Latossolos Amarelos e Argissolos dos tabuleiros costeiros do estado de Alagoas. Revista Brasileira de Ciência do Solo 34(2):473–486. https://doi.org/10.1590/S0100-06832010000200021

Lin S (2010) Rank aggregation methods. Wiley Interdisciplinary Reviews: Computational Statistics 2(5):555–570. https://doi.org/10.1002/wics.111

Liu S, Zhang X, Wang Y, et al (2025) Evaluation of cultivated land quality based on principal component analysis and fuzzy scoring under different cropping systems in the black soil region of China. Ecological Indicators 170:112100. [VERIFICAR DADOS BIBLIOGRÁFICOS REAIS ANTES DA SUBMISSÃO]

Lundberg SM, Lee SI (2017) A unified approach to interpreting model predictions. In: Advances in Neural Information Processing Systems, pp 4765–4774

Mahajan GR, Das B, Morajkar S, et al (2021) Comparison of soil quality indexing methods for salt-affected soils of Indian coastal region. Environmental Earth Sciences 80:725. https://doi.org/10.1007/s12665-021-09922-x

Majid SI, Kumar M, Bhadwal SS (2025) Application of explainable artificial intelligence to decode water-induced soil erosion in Lidder watershed of the Greater Himalayas. Stochastic Environmental Research and Risk Assessment 39:1691–1716. https://doi.org/10.1007/s00477-025-03042-9

Milborrow S (2023) earth: Multivariate adaptive regression splines. R package version 532 Derived from mda:mars by T. Hastie and R. Tibshirani

Moitinho MR, Fernandes C, Truber PV, et al (2020) Arbuscular mycorrhizal fungi and soil aggregation in a no-tillage system with crop rotation. Journal of Plant Nutrition and Soil Science 183(4):482–491. https://doi.org/10.1002/jpln.201900456

Mukherjee A, Lal R (2014) Comparison of soil quality index using three methods. PLoS ONE 9(8):e105981. https://doi.org/10.1371/journal.pone.0105981

Munda G (2012) Choosing aggregation rules for composite indicators. Social Indicators Research 109(3):337–354. https://doi.org/10.1007/s11205-011-9911-9

Mundfrom DJ, Shaw DG, Ke TL (2005) Minimum sample size recommendations for conducting factor analyses. International Journal of Testing 5(2):159–168. https://doi.org/10.1207/s15327574ijt0502_4

Nabiollahi K, Golmohamadi F, Taghizadeh-Mehrjardi R, et al (2018) Assessing the effects of slope gradient and land use change on soil quality degradation through digital mapping of soil quality indices and soil loss rate. Geoderma 318:16–28. https://doi.org/10.1016/j.geoderma.2017.12.024

Nabiollahi K, Heshmat E, Mosavi A, et al (2020) Assessing the influence of soil quality on rainfed wheat yield. Agriculture 10(10):469. https://doi.org/10.3390/agriculture10100469

Oliveira FCC, Pedrotti A, Souza JLS, et al (2020) Soil physical properties and soil organic carbon content in northeast Brazil: long-term tillage systems effects. Scientia Agricola 77(4):e20180166. https://doi.org/10.1590/1678-992x-2018-0166

Oliveira FCC, Ferreira GWD, Assunção SJR, et al (2024) Long-term impacts of tillage and cover cropping on soil organic carbon and carbon oxidizable fractions in a tropical sandy soil. Journal of Soil Science and Plant Nutrition 24:3021–3035. https://doi.org/10.1007/s42729-024-02064-6

Pacci S, Dengiz O, Alaboz P, et al (2026) A smart approach to soil quality evaluation by integrating hesitant fuzzy-AHP and artificial intelligence for multi-criteria decision. International Journal of Environmental Science and Technology https://doi.org/10.

1007/s13762-025-06787-6

de Paul Obade V, Lal R (2016) Towards a standard technique for soil quality assessment. Geoderma 271:116–126. https://doi.org/10.1016/j.geoderma.2016.02.019

Peoples MB, Brockwell J, Herridge DF, et al (2009) The contributions of nitrogen-fixing crop legumes to the productivity of agricultural systems. Symbiosis 48:1–17. https://doi.org/10.1007/BF03179980

Pheap S, Lefrévre C, Tivet F, et al (2025) Fuzzy soil quality indexing for evaluating rice-based cropping systems under conservation agriculture in Cambodia. Agriculture, Ecosystems & Environment 361:108812. https://doi.org/10.1016/j.agee.2024.108812

Ray S, Danks NP, Calvo Mora A (2022) Building and estimating structural equation models with the seminr package in R. Structural Equation Modeling: A Multidisciplinary Journal 29(3):469–478. https://doi.org/10.1080/10705511.2021.2023014

Rezaee L, Moosavi AA, Davatgar N, et al (2020) Soil quality indices of paddy soils in Guilan province of northern Iran: Spatial variability and their influential parameters. Ecological Indicators 117:106566. https://doi.org/10.1016/j.ecolind.2020.106566

Santos JA, Pedrotti A, Holanda FSR, et al (2024) Impacts of the tillage systems on the production of green corn (Zea mays L.) in long-term plots in Northeastern Brazil. Soil Use and Management 40(1):e12929. https://doi.org/10.1111/sum.13061

Sarstedt M, Ringle CM, Hair JF (2022) Partial least squares structural equation modeling. Handbook of Market Research pp 587–632. https://doi.org/10.1007/978-3-319-57413-4_15

Shahriari M, Delbari M, Afrasiab P, et al (2023) Predicting regional spatial distribution of soil texture in floodplains using remote sensing data: a case of southeastern Iran. Catena 182:104149. https://doi.org/10.1016/j.catena.2019.104149

da Silva MF, Fernandes MMH, Fernandes C, et al (2021) Contribution of tillage systems and crop succession to soil structuring. Soil and Tillage Research 209:104924. https://doi.org/10.1016/j.still.2020.104924

Thomaz EL, Antoneli V (2022) Long-term soil quality decline due to the conventional tobacco tillage in Southern Brazil. Archives of Agronomy and Soil Science 68(8):1053–1070. https://doi.org/10.1080/03650340.2020.1852550

Torbert HA, Krueger E, Kurtener D (2008) Soil quality assessment using fuzzy modeling. International Agrophysics 22:365–370

Venkateswarlu M, Rallapalli S, Singh A (2025) Macro and micronutrient based soil fertility zonation using fuzzy logic and geospatial techniques. Scientific Reports 15:12184. https://doi.org/10.1038/s41598-025-12184-3

Wadoux AMJC, Minasny B, McBratney AB (2020) Machine learning for digital soil mapping: applications, challenges and suggested solutions. Earth-Science Reviews 210:103359. https://doi.org/10.1016/j.earscirev.2020.103359

Ye Y, Sun X, Zhao J, et al (2022) Establishing a soil quality index to assess the effect of thinning on soil quality in a Chinese fir plantation. European Journal of Forest Research 141:885–900. https://doi.org/10.1007/s10342-022-01471-7

Zeraatpisheh M, Bakhshandeh E, Hosseini M, et al (2020) Assessing the effects of deforestation and intensive agriculture on the soil quality through digital soil mapping. Geoderma 363:114139. https://doi.org/10.1016/j.geoderma.2019.114139

Zhang D, Chen H, Guo Y, et al (2024) Effects of different tillage and fertilizer on soil quality under wheat-maize rotation in the North China Plain. Land Degradation & Development 35(4):1394–1407. https://doi.org/10.1002/ldr.5048

Zhao H, Wu L, Zhu S, et al (2022) Sensitivities of physical and chemical attributes of soil quality to different tillage management. Agronomy 12(5):1153. https://doi.org/10.3390/agronomy12051153